Cargando datos en R

Plataforma de Formación On line del Instituto Andaluz de

Administración Pública

Curso: (I22F-PT05) Entorno de Programación R

Libro: Cargando datos en R

Sitio:

Imprimido por: ALFONSO LUIS MONTEJO RAEZ

Día: lunes, 11 de abril de 2022, 10:54

Tabla de contenidos

1. Introducción

- 1.1. Archivos de texto CSV o DSV
- 1.2. Archivos de texto desde Internet
- 1.3. Archivos de texto. Ancho fijo
- 1.4. Archivos Excel
- 1.5. Archivos ODS
- 1.6. Archivos DBF
- 1.7. Archivos PX
- 1.8. Archivos PDF

1. Introducción

El formato de datos nativo de R es el **RData** pero, en general, no dispondremos de los datos directamente en él y tendremos que cargarlos en R desde otras fuentes.

Para realizar la carga de datos de otros formatos podemos hacerlo de dos formas: **usando el asistente de RStudio** o **utilizando paquetes específicos** para determinados tipos de ficheros.

En el primer caso, RStudio cuenta con un asistente que nos ayuda en la tarea de importar datos desde la pestaña **Environment**. El asistente carga los datos con la ayuda de varios paquetes que vienen instalados en R.

Los formatos que acepta el asistente son:

- Paquetes base o readr: Formato de texto (csv, dsv).
- Paquete readxl. Archivos de Excel.
- Paquete Haven. Archivos de SPSS, SAS y Stata.

Para los tipos de ficheros que no vienen en el asistente tenemos que usar paquetes específicos, que tendremos que instalar y cargar antes de poder usarlos.

Nosotros vamos a ver la carga de los siguientes formatos:

- Paquete readODS. Archivos de Calc de LibreOffice.
- Paquete foreign. Archivos de tipo DBF.
- Paquete pxR. Archivos de tipo PcAxis.
- Paquete tabulizer. Archivos PDF.

Para ver como se cargan los archivos de los distintos tipos vamos a usar ejemplos para cada uno de ellos.

1.1. Archivos de texto CSV o DSV

El formato más habitual para el intercambio de datos es el texto plano.

En este tipo de ficheros los datos de cada variable vienen separados por un carácter, que suele ser una coma o un punto y coma. Los primeros se denominan **ficheros csv** (comma separated values) y los segundos **ficheros dsv** (delimited separated values).

Para cargar este tipo de ficheros en RStudio, podemos hacerlo por dos vías: o usando el asistente o las órdenes **read.csv()** para el formato csv y **read.csv2()** para el formato dsv.

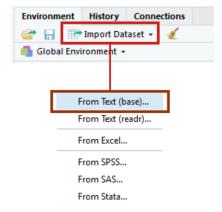
En la orden podemos especificar, entre otros, los siguientes parámetros:

- Valor del separador (, o ;)
- Valor de los decimales (. o ,)
- Cabecera de datos

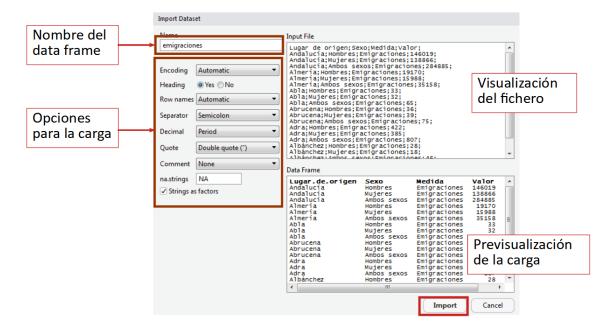
<u>Ejemplo</u>

Vamos a usar el asistente de RStudio para cargar el fichero **emigraciones.txt** con datos de las emigraciones desde Andalucía por municipio y sexo. Este archivo tiene los valores separados por ; y los nombres de las variables están en la primera fila.

Para cargarlo tenemos que pulsar **Import Dataset** de la pestaña **Environment** donde elegimos el tipo de archivo a cargar, que en nuestro caso es de Texto.



Después navegamos para buscar el archivo a cargar en su localización (normalmente en el disco duro o un pendrive) y se abre el asistente donde podremos elegir las opciones adecuadas para la carga del archivo.

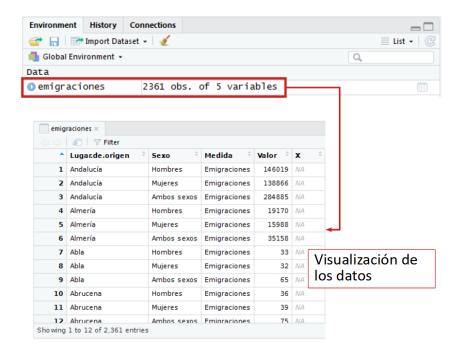


Los parámetros que tenemos que determinar son:

- Nombre del data frame que se va a crear en R cuando finalice la carga.
- Código de carácteres del fichero (Encoding). Cual es el sistema de caracteres empleado en el fichero (normalmente UTF-8 o ANSI).
- Separador de los valores (Separator). En nuestro caso los valores están separados por ;
- Nombres de las variables (Header). Si la primera línea del fichero contiene el nombre de las variables.
- **Separador de decimales (Decimal)**. En el caso de datos numéricos con decimales podemos elegir si es un punto o una coma el caracter que separa la parte decimal.

Cuando terminamos de elegir todas las opciones pulsamos el botón Import.

Una vez cargado el fichero podemos ver el objeto emigraciones creado en la pestaña de Environment.



1.2. Archivos de texto desde Internet

La ubicación del fichero no tiene porque ser un fichero en local si no que puede ser también un fichero que esté en internet.

En este caso podemos cargar el fichero de datos usando la orden **read.csv()** indicando, como origen del archivo, la URL donde se encuentra el fichero.

<u>Ejemplo</u>

En este caso vamos a cargar un fichero de texto que contiene los datos de paro registrado por municipios para el año 2006 que se encuentra en la LIRI

https://sede.sepe.gob.es/es/portaltrabaja/resources/sede/datos_abiertos/datos/Paro_por_municipios_2006_csv.csv

La orden que vamos a usar para cargar el archivo desde internet sería:

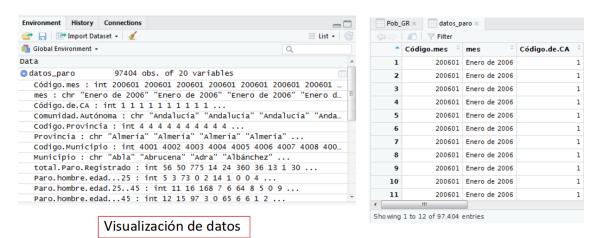
```
> read.csv(url,sep=';',header=T,skip=1,as.is=T)->datos_paro
```

Opciones empleadas:

- sep=';' Usamos separador ;
- header=T Los datos tienen el nombre de las variables en la cabecera
- skip=1 Que se salte la primera línea (que es el título de la tabla)
- as.is=T Que mantenga el formato original de los datos.

Url es un objeto de texto donde hemos almacenado la dirección desde donde se tienen que bajar los datos.

Una vez cargados los datos se crea el objeto datos_paro en la pestaña de Environment.



Se han cargado 97.404 registros con información de 20 variables.

1.3. Archivos de texto. Ancho fijo

Los ficheros de **ancho fijo** tienen la particularidad de que los valores de las variables no están separados por ningún carácter ya que vienen determinados por la posición que ocupa cada valor dentro de una fila.

Para poder cargar este tipo de datos es necesario conocer previamente el **diseño de registro**. Éste es un documento donde se indican las variables que contiene el fichero, junto con la longitud o posición que ocupan y la codificación usada para las variables categóricas.

Este formato es el usado para la difusión de microdatos de encuestas e información estadística oficial.

Para leer un fichero de este tipo se usa la orden read.fwf().

Ejemplo

Vamos a importar los microdatos de la estadística de variaciones residenciales del INE que se encuentran en el archivo EVR_2016.

Lo primero que necesitamos es conocer el diseño de registro para saber que variables contiene el archivo y cual es su ubicación (Longitud de cada campo).

					Disello de l'egistio	
Longitud: 37						
Variable	Descripción	Longitud	Inicio	Fin	Observaciones	Valores
SEXO	Sexo	1	1	1		1> Hombre y 6>Mujer
PROVNAC	Provincia de nacimiento	2	2	3	Los nacidos en el extranjero se identifican con el código '66'.	01,02 52> Consultar listado PROV
MUNINAC	Municipio o país de nacimiento	3	4	6	Para los nacidos en España se codifica el municipio de nacimiento y para los nacidos en el extranjero se codifica el país de nacimiento. Se blanquea el código de los municipios de nacimiento con población inferior a 10.000 habitantes.	Consultar listado MUNI1
EDAD	Edad en el momento de la VR	3	7	9	Edad en el momento de la variación. Se ha calculado para todos los años teniendo en cuenta los meses de nacimiento y variación, no los días.	
MESNAC	Mes de nacimiento	2	10	11		
AÑONAC	Año de nacimiento	4	12	15		
CNAC	Nacionalidad	3	16	18		Consultar listado CNAC

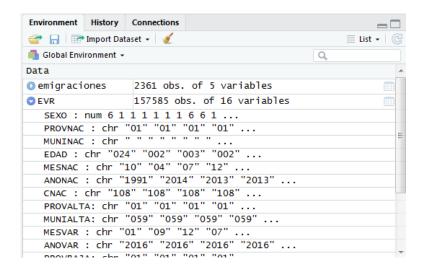
Disaño da ragistro

La orden para cargar el archivo es read.fwf(),

con los siguientes parámetros:

- Ubicación del fichero a cargar.
- Valores de longitud de los campos. Esta información la encontramos en el diseño de registro e indica la longitud que ocupa cada variable dentro del fichero.
- Nombres de las variables. Listado con los nombres que le queremos poner a las variables.
- Tipo de dato de cada variable. Tipo de dato (normalmente numerico o carácter).
- Header. Indica si el fichero cuenta en su primera con una cabecera con información. En nuestro caso no la lleva y usamos el F (False).

Una vez cargado el fichero podemos ver el objeto **EVR** creado en la pestaña **Environment**.



Este objeto tiene 157.585 registros y 16 variables.

1.4. Archivos Excel

Los ficheros Excel son propios de las hojas de cálculo de Microsoft Office y son muy usados para el intercambio y difusión de tablas de datos.

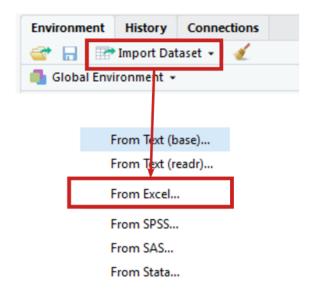
Para leer este tipo de formato necesitamos el **paquete readxl**, por lo que antes de usarlo, debemos instalarlo y cargarlo. La orden para leer este tipo de ficheros es **read_excel()**, que nos sirve para cargar archivos tanto xls como xlsx.

Otra opción para cargar estos ficheros es usar el asistente de RStudio para ficheros Excel.

<u>Ejemplo</u>

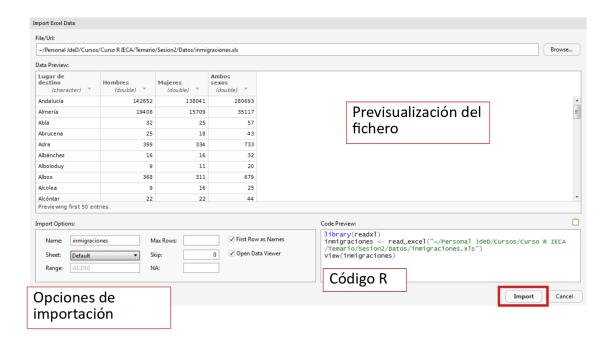
Vamos a usar el asistente de RStudio para cargar el fichero **inmigraciones.xls** que contiene los datos de inmigraciones por municipio y sexo hacia Andalucía para el año 2016.

Para cargarlo tenemos que pulsar **Import Dataset** de la pestaña **Environment** donde elegimos el tipo de archivo a cargar, que en nuestro caso es de Excel.



Una vez elegido el tipo de archivo, se abre el asistente donde podemos elegir las opciones adecuadas para la carga del archivo.

Lo primero es buscar el archivo a cargar pulsando el botón **Browse** y navegando para localizarlo en su ubicación (normalmente en el disco duro o un pendrive) y, a continuación, elegir las opciones adecuadas para la carga del archivo.



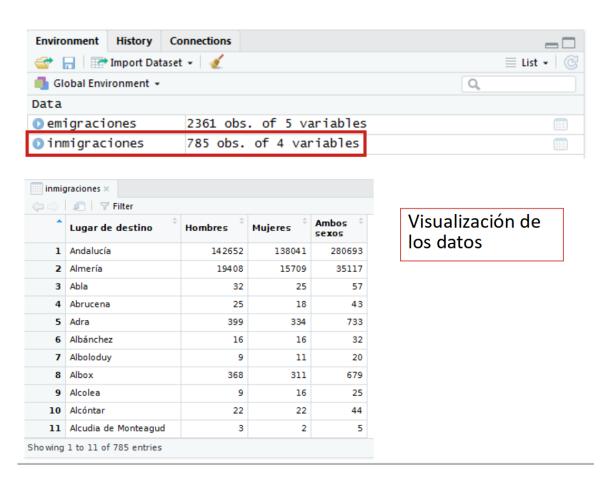
Los parámetros que tenemos que determinar son:

- Nombre del data frame (Name) que se va a crear en R cuando finalice la carga.
- Hoja (Sheet). Si el fichero Excel tiene más de una hoja aquí podemos elegir cual de ellas queremos cargar.

En la ventana **Code Preview** podemos ver como se va construyendo la orden que vamos a usar para cargar el fichero Excel. En esta ventana nosotros podemos modificar y escribir las opciones que queramos para adecuarlas a nuestras necesidades.

Cuando terminamos de elegir todas las opciones pulsamos el botón Import.

Una vez cargado el fichero podemos ver el objeto inmigraciones creado en la pestaña de Environment.



Este objeto cuenta con 785 registros y 4 variables.

1.5. Archivos ODS

Los ficheros de formato ods son propios de las hojas de cálculo de Libreoffice y Openoffice.

Para leer este tipo de formato necesitamos el paquete readODS, por lo que antes de usarlo, debemos instalarlo y cargarlo.

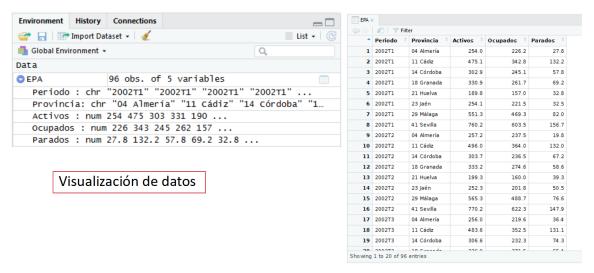
La orden para leer este tipo de ficheros es read_ods().

Ejemplo

Vamos a cargar en R el fichero EPA.ods que contiene información sobre la Encuesta de Población Activa por provincias para Andalucía.

- > library(readODS)
- > read_ods('E:\\curso R IECA\\Temario\\Sesion2\\Datos\\EPA.ods',col_names=T)->EPA

Para cargar el fichero ods simplemente tenemos que indicar la ruta donde se encuentra el fichero y usar el parámetro **col_names=T** que indica que la primera línea contiene el nombre de las variables.



Una vez cargado el fichero se crea un objeto denominado EPA que cuenta con 96 registros y cinco variables.

1.6. Archivos DBF

Los ficheros en **formato dbf** son propios de las bases de datos dBase. Éste es usado por las capas cartográficas shape (shp) para almacenar la información alfanumérica.

Para leer este tipo de formato necesitamos el paquete foreign, por lo que antes de usarlo, debemos instalarlo y cargarlo.

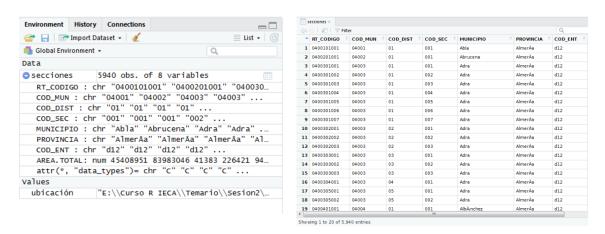
La orden para leer este tipo de ficheros es read.dbf().

<u>Ejemplo</u>

Vamos a cargar en R la información alfanumérica de una capa cartográfica en formato shape, que contiene la información de las secciones censales de 2017.

- > library(foreign)
- > ubicación<-'E:\\Curso R IECA\\Temario\\Sesion2\\Datos\\2017\\sc_2017.dbf'</pre>
- > read.dbf(ubicación,as.is=T)->secciones

Para cargar el fichero dbf simplemente tenemos que indicar la ruta donde se encuentra el fichero y usar el parámetro **as.is=T** para que respete el formato original de los datos.



Visualización de datos

Una vez cargado el fichero se crea un objeto denominado secciones que cuenta con 5.940 registros y ocho variables.

1.7. Archivos PX

Los ficheros en **formato px** son tablas de datos del programa PCAxis. Este formato es el que usan los organismos públicos de estadística, como el INE, para la descarga de tablas de datos.

Para leer este tipo de formato necesitamos el paquete pxR, por lo que antes de usarlo, debemos instalarlo y cargarlo.

La orden para leer este tipo de ficheros es read.px().

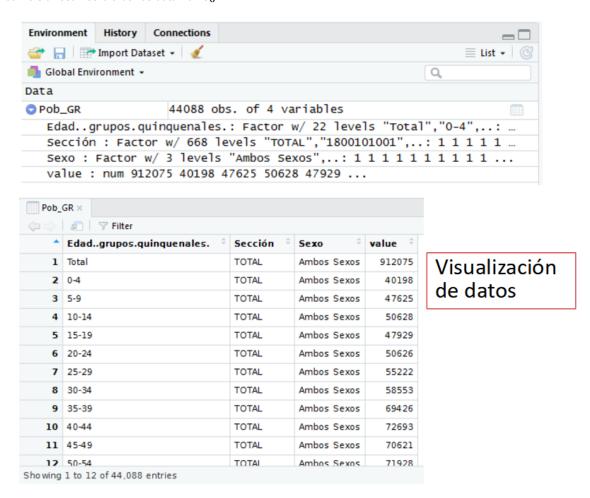
<u>Ejemplo</u>

Vamos a cargar en R la información del **fichero 1801_2018.px** que contiene información de población de la provincia de Granada por sexo, sección censal y grupo de edad.

.
> library(pxR)
> read.px('F:\\Curso R IECA\\Temario\\Sesion2\\Datos\\1801_2018.px')->Pob_GR
> as.data.frame(Pob_GR)->Pob_GR

Para cargar el fichero px simplemente tenemos que indicar la ruta donde se encuentra el fichero.

Este paquete genera un tipo de dato propio, similar a una lista, que debemos convertir en un data frame para poder trabajar él. Para realizar la conversión usamos la orden **as.data.frame()**.



Una vez cargado el fichero se crea un objeto denominado Pob_GR que cuenta con 44.088 registros y cuatro variables.

1.8. Archivos PDF

En ocasiones hay organismos que difunden información estadística en formato PDF donde se incluyen tablas.

A traves del **paquete tabulizer** se puede extraer de un documento pdf la información contenida en formato de tabla, siempre que ésta tenga una estructura reconocible.

Este paquete no está dentro de la base de R, por lo que tenemos que instalarlo y cargarlo antes de usarlo.

La orden básica para extraer información de un pdf es extract_tables() o extract_text().

Ejemplo

Para mostrar el uso de este paquete vamos a utilizar como ejemplo la información que publica el Servicio Andaluz de Empleo en su informe sobre la mujer y el mercado de trabajo andaluz 2018.

En las páginas 114 y 120 de ese informe existe información en formato de tabla que queremos extraer. En concreto se trata de la tabla de los Municipios con más mujeres extranjeras empadronadas y la tabla con los Países de origen de las mujeres contratadas.

Municipio	Mujeres extranjeras	% municipio sobre total
Málaga	22.020	7,20%
Marbella	17.602	5,76%
Sevilla	17.272	5,65%
Mijas	12.833	4,20%
Fuengirola	12.329	4,03%
Roquetas de Mar	11.101	3,63%
Ejido, El	10.981	3,59%
Almería	9.047	2,96%
Benalmádena	8.411	2,75%
Estepona	7.514	2,46%
Granada	7.238	2,37%
Torremolinos	6.879	2,25%
Níjar	5.310	1,74%
Córdoba	4.529	1,48%
Algeciras	4.273	1,40%
Vélez-Málaga	3.811	1,25%
Moguer	2.990	0,98%
Vícar	2.854	0,93%
Huelva	2.811	0,92%
Motril	2.790	0,91%

Vamos a usar la función extract_tables() a la que le podemos definir los siguientes parámetros:

- ubicación. Donde está el fichero a extraer. Puede ser una URL.
- pages. Página del documento donde está la tabla.
- output. Formato de la salida de los datos (data frame, matriz, etc).
- enconding. Juego de carcteres usado en la codificación del texto.

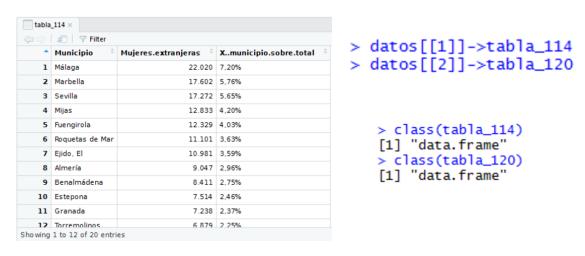
El resultado de esta función se almacena en una lista dejando cada tabla en un objeto dentro de la lista.

```
> library(tabulizer)
> extract_tables('F:\\Curso R IECA\\Temario\\Sesion3\\Datos\\Mujer_2018.pdf',
+ output = 'data.frame',encoding = 'UTF-8',pages=c(114,120))->datos
```



El resultado es una lista con dos data frames

Para obtener la información de la lista, donde están almacenadas las tablas, tenemos que acceder usando el doble corchete.



Normalmente, a la información que se obtiene hay que hacerle una limpieza básica ya que se almacena exactamente como aparece en la tabla (con los símbolos de %, los puntos de los miles, etc.)